

PostRainBench: A comprehensive benchmark and new model for precipitation forecasting

Léo Porte, Grégoire Goujon, Mehdi Lakbar

Introduction

La prévision des précipitations intensives reste un défi majeur en météorologie. Notre étude présente "PostRainBench", un benchmark innovant pour le post-traitement des prévisions numériques, combinant des techniques avancées de l'IA pour améliorer la précision des prédictions météorologiques:

- **Channel Attention Module (CAM)** optimise la sélection des variables en modélisant les relations complexes entre différentes variables météorologiques.
- **Multitask Learning** est une approche hybride qui associe la régression et la classification, améliorant la précision des prévisions.

Ce travail vise à réduire l'impact des événements climatiques extrêmes en affinant les prévisions des précipitations.

Contexte & Datasets

Les entrées du modèle sont des **Numerical Weather Predictions (NWP)**, issues de méthodes pré-existantes correspondant aux meilleures performances dans l'état de l'art. Ces entrées contiennent des informations sur **l'état météorologique** à un instant t (vitesse du vent, température, pression...).

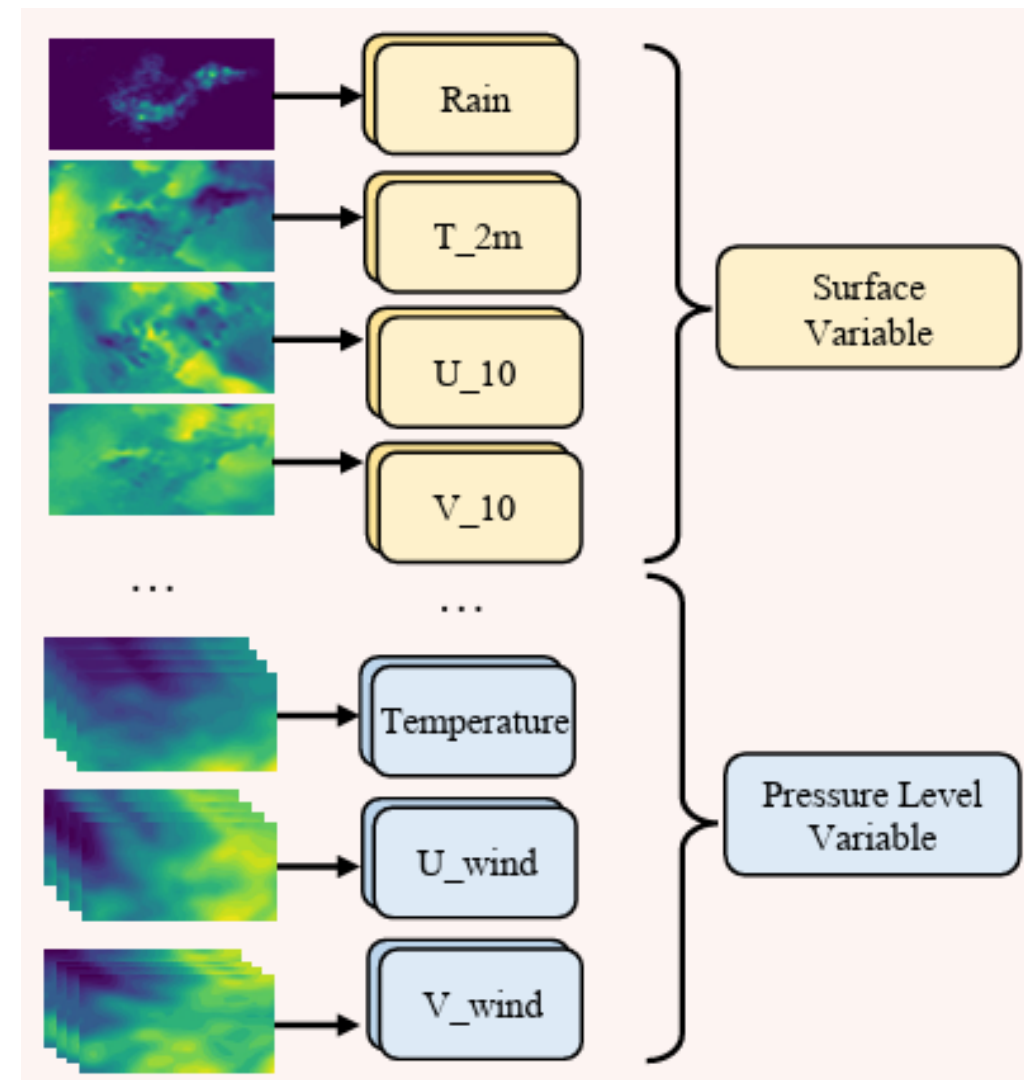


Figure 1: Numerical Weather Predictions

Les prédictions NWP X_t sont dérivées du modèle NWP au temps $t - L - \tau$, constituant une séquence notée comme $X_t = x(t - L), x(t - L + 1), \dots, x(t - 2), x(t - 1)$.

Le **Dataset KoMet** que nous avons utilisé, collecté en Corée du Sud, généré par un modèle global de prévision météorologique numérique fournit des prévisions horaires pour diverses variables atmosphériques. Les variables se répartissent en deux catégories : les variables de niveau de pression et les variables de surface. Pour les besoins du benchmarking, 12 variables sur les 122 sont sélectionnées selon les experts.

Méthode & Modèle principal

1. CAM

Les approches traditionnelles de modélisation météorologique, souvent limitées par une sélection de variables basée sur l'expertise ou par l'utilisation exhaustive des données disponibles, ne parviennent pas à exploiter pleinement les capacités de modélisation. Le CAM affine la sélection des variables en modélisant les relations complexes entre elles, utilisant des opérations de pooling moyen et maximum pour générer des descripteurs de contexte spatial, traités ensuite par un perceptron multicouche (MLP) pour produire une carte d'attention aux canaux. Cette méthodologie vise à améliorer la précision des prévision météorologiques multi-variables. En résumé, l'attention aux canaux est calculée comme suit:

$$M_c(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))) = \sigma(W_1(W_0(F_{\text{avg}})) + W_1(W_0(F_{\text{max}}))))$$

2. MultiTask Learning

- La première partie du MultiTask Learning est constituée d'un **Swin-Unet**. Dans cette architecture, les patches d'image tokenisés sont introduits dans l'architecture Encodeur-Décodeur en forme de U basée sur le Swin Transformer, avec des connexions de saut pour l'apprentissage des caractéristiques sémantiques locales et globales.
- **Hybrid Learning** : Dans cette étude, nous explorons la prévision des précipitations en combinant les tâches de régression et de classification au sein d'un cadre d'apprentissage multi-tâches, utilisant à la fois la perte d'Erreur Quadratique Moyenne (MSE) et l'Entropie Croisée pondérée (CE), avec un hyperparamètre α . Cette approche vise à optimiser l'apprentissage des caractéristiques essentielles, tout en abordant le déséquilibre des classes dans la prévision des précipitations.

La fonction de perte hybride est définie comme :

$$L_{\text{hybride}} = L_{\text{cls}} + \alpha L_{\text{reg}}$$

où L_{cls} est la perte d'entropie croisée pondérée, L_{reg} est la perte d'erreur quadratique moyenne

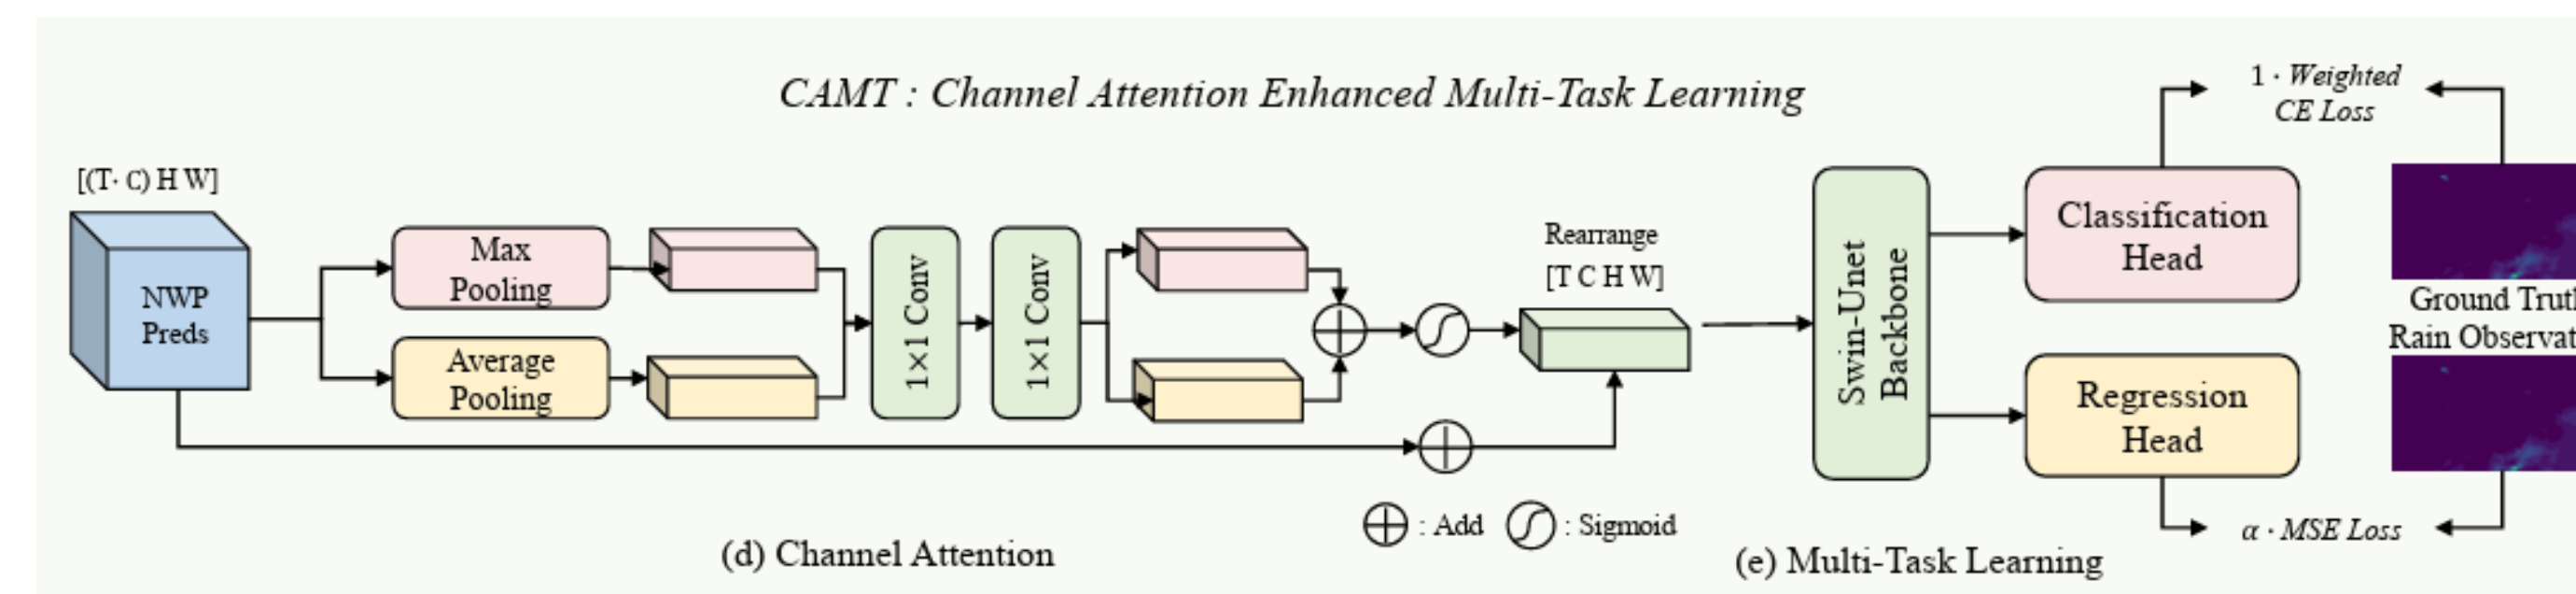



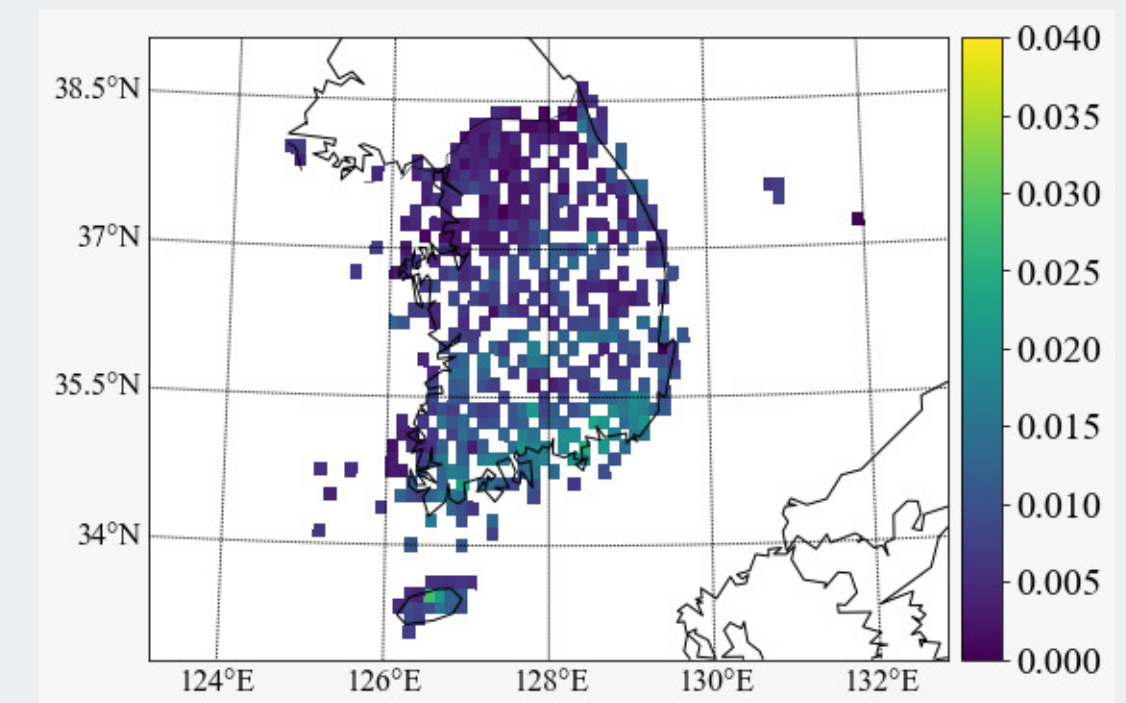
Figure 2: Architecture du modèle Channel-Attention Enhanced Multi-Task Learning

Protocole expérimental & Résultats

Sortie du modèle



(a) Input du modèle



(b) Prédiction en sortie du modèle

Comparaison algorithmes

Afin de tester la performance du modèle présenté dans l'article, nous avons comparé ses résultats à ceux de différents algorithmes :

Algorithme	HSS	CSI
CAM + Swin-Unet	0.000007	0.11743
ConvLSTM	0.018844	0.122903
Metnet	0.000215	0.104405
Unet	0.003765	0.111731
CAM + Unet	0.012439	0.065424
ConvGRU	0.000297	0.120695
ViT	0.0	0.0
CAMViT	0.0	0.120623

Table 1. Valeurs de HSS et CSI pour les algorithmes testés.

Conclusion & Critique de l'article

- Article bien détaillé, assez bien reproductible
- Benchmark très spécifique, peu d'applications possibles
- Fonction de perte hybride pas utile
- Ingénierie plutôt que recherche

References

- [1] Yujin Tang et Al.
Postrainbench: A comprehensive benchmark and anewmodelforprecipitation forecasting.
NeurIPS Conference 2023, 2023.